

# Cardiac arrhythmia classification using deep learning algorithm integrated with HL7 protocol

Harold Alemán, Sofía Céspedes, Margory Viviano, and Nicole Acuña


**Abstract**— Cardiovascular disease (CVD) is the leading cause of death worldwide, accounting for 31% of all deaths, and cardiac arrhythmias are one of the main types of CVD. In Peru, the prevalence of arrhythmias is high, especially in people over 60 years of age, and access to cardiologists is limited, particularly in rural areas. This study proposes a deep learning algorithm for arrhythmia classification based on electrocardiographic (ECG) signals obtained from Holter monitors, integrating the HL7 standard to improve interoperability with health information systems. The BITalino (R)evolution kit was used for data acquisition, and an interface was developed to allow visualization of signals and classifications. The system demonstrated a significant improvement in ECG signal quality and 97.3% accuracy in arrhythmia classification, which may contribute to earlier and more accurate diagnosis, especially in areas with limited medical resources.

**Index Terms**— arrhythmia, deep learning, Holter monitor, HL7

## I. INTRODUCTION

Las enfermedades cardiovasculares (ECV) son alteraciones en el ritmo cardíaco y pueden indicar disfunciones en las aurículas o ventrículos. Según la organización mundial de la salud (OMS), las ECV son la principal causa de muerte en todo el mundo, representando el 31% de ellas [1]. En este contexto, las arritmias son una de las principales ECV y son trastornos que afectan a la frecuencia y/o al ritmo de los latidos del corazón. En Perú, las arritmias tienden a presentarse con mayor incidencia en personas mayores de 60 años, teniendo un 50.8% de riesgo [2]. Entre las arritmias más comunes tenemos, por ejemplo, la fibrilación auricular, que es la arritmia más común a nivel mundial y la padecen 1 de cada 25 adultos mayores de 60 años [3], y también tenemos a la taquicardia ventricular, ya que el 15% de pacientes con enfermedad coronaria tienen esta condición [4] y es la principal causa de muerte cardíaca súbita en pacientes con cardiomiopatías isquémicas y no isquémicas [5]. Por ello, surge la necesidad de una detección temprana de estas arritmias. Actualmente, la herramienta más utilizada para detección temprana y manejo de arritmias en un paciente es el monitor Holter, el cual permite vigilar la actividad eléctrica de un paciente en un periodo de 24 a 48 horas, proporcionado la señal electrocardiográfica (ECG), con dos datos primarios

para analizar, el complejo QRS y el intervalo RR (ver Figura 1) [6], para finalmente ser interpretada por un especialista.



**Fig 1.** Puntos e intervalos de interés en la representación eléctrica de un latido.

En Perú, la cantidad de médicos especialistas es preocupante, habiendo 0,7 médicos especialistas por cada 10 mil asegurados y en la especialidad de cardiología las cifras son aún más preocupantes, ya que en 2013 solo había 148 cardiólogos registrados, según el Ministerio de Salud [7]. Esta falta de especialistas plantea desafíos críticos para el diagnóstico y tratamiento oportunos de estas arritmias. En este contexto, salen a la luz aún más las brechas existentes entre zonas urbanas y zonas rurales donde el acceso a servicios médicos es limitado, ya que 6 de cada 10 médicos colegiados se encuentran en Lima o Callao.

Además de ello, los monitores Holter tradicionales presentan una limitación en la integración de la señal ECG obtenida y los sistemas de información de salud electrónicos, por lo que a menudo estos datos requieren procesos manuales de transferencia y conversión, lo que puede llevar a errores y retrasos en la interpretación médica. [8] Asimismo, luego de la obtención de las señales ECG del monitor Holter, la interpretación es compleja debido a los patrones eléctricos del corazón y la superposición de arritmias con la actividad normal. Siendo que el 15% de las muertes por enfermedades cardíacas a nivel mundial se deben a errores en la interpretación de estas señales [9]. Si bien existen tecnologías de monitorización remota, la identificación precisa de ritmos cardíacos sigue siendo un reto debido a factores ambientales y la necesidad de interpretación experta.

Harold Aleman, Sofia Céspedes, Margory Viviano and Nicole Acuña are with the Program of Biomedical Engineering, Faculty of Sciences and Engineering, Universidad Peruana Cayetano Heredia, Lima 15102 Peru (e-mail: [harold.aleman@upch.pe](mailto:harold.aleman@upch.pe); [sofia.cespedes@upch.pe](mailto:sofia.cespedes@upch.pe); [chris.viviano@upch.pe](mailto:chris.viviano@upch.pe); [nicole.acuna@upch.pe](mailto:nicole.acuna@upch.pe))

Es por ello, que en zonas rurales la tarea de interpretación de estas señales ECG del monitor Holter así como un manejo efectivo de esta información se complica aún más. No detectar problemas cardíacos o no llevar un registro de las actividades cardíacas de un paciente que padece arritmias en zonas rurales, puede conllevar a emergencias de atención inmediata, gastos económicos en una familia o puede resultar fatal.

Walinjkar et al. (2017) desarrollaron un sistema para la adquisición de datos de ECG y la predicción de arritmias en tiempo real, integrando un sensor ECG de 3 derivaciones con software que utiliza el estándar HL7 FHIR para la actualización en tiempo real de registros electrónicos de salud (EHR) [10]. Por otro lado, Park et al. (2013) desarrollaron un sistema para la detección y clasificación de arritmias utilizando un clasificador k-NN. En el que se utilizó un algoritmo de Pan-Tompkins para extraer características del ECG y clasificar los latidos con alta precisión, logrando una sensibilidad del 97.1% y una especificidad del 96.9% en la clasificación de latidos. [11]. Kumari et al. (2022), a su vez, presentaron un enfoque basado en FBSE y un algoritmo k-NN optimizado con Jaya para la detección de arritmias cardíacas, logrando una precisión del 99.49%, una sensibilidad del 95.43% [12].

Si bien, existen soluciones existentes que ya abordan estos diversos problemas por separado, todavía faltan tecnologías que puedan integrar de manera efectiva soluciones a todos estos problemas. Es por ello que el objetivo de este estudio, es poder plantear las bases iniciales de una solución que permita la detección de arritmias para señal ECG extraída de un monitor Holter que además integre el estándar HL7 para facilitar la interoperabilidad.

## II. PLANTEAMIENTO DEL PROBLEMA

La clasificación de arritmias cardíacas es fundamental para mejorar el diagnóstico temprano y el tratamiento efectivo de enfermedades cardiovasculares. Las arritmias pueden manifestarse de diversas formas y pueden indicar condiciones potencialmente graves como la fibrilación auricular o taquicardias ventriculares, que requieren intervención médica inmediata [13].

Actualmente, la mayoría de los métodos de diagnóstico basados en electrocardiogramas (ECG) utilizan técnicas manuales o heurísticas para identificar patrones anormales en las señales eléctricas del corazón [14]. Sin embargo, la efectividad de estos enfoques puede verse limitada por la complejidad de las señales ECG y la variabilidad interindividual en la presentación de arritmias [15].

La falta de métodos automatizados y precisos para la clasificación de arritmias puede resultar en diagnósticos erróneos o retrasados, afectando negativamente la salud cardiovascular de los pacientes [16]. Además, la interoperabilidad limitada entre sistemas de salud y dispositivos de monitoreo ECG dificulta la integración efectiva de datos y la colaboración entre profesionales de la

salud [17]. Cerca a ello, la gestión y el intercambio de datos obtenidos mediante los monitores Holter convencionales representan un desafío significativo en la actualidad. Por eso mismo es que la falta de estandarización en la estructura y el formato de los datos generados por los holter, debido a la diversidad de formatos y la falta de un estándar universal [18, 19]. Esta falta de estandarización conduce a inconsistencias en la interpretación de los datos, retrasos en el análisis clínico y posibles errores en la toma de decisiones médicas.


## III. PROPUESTA DE SOLUCIÓN

La propuesta de solución consiste en el desarrollo de un algoritmo de deep learning que permita el análisis de señales ECG obtenidas de monitores Holter para la posterior clasificación de arritmias. Asimismo, diseñamos una interfaz en la cual se podrán visualizar tanto las señales ECG como las clasificaciones arrojadas por nuestro algoritmo y utiliza el estándar HL7 para garantizar una monitorización del estado del paciente, para garantizar una integración fluida y eficiente con los diferentes sistemas de información existentes en las instituciones de salud.

## IV. METODOLOGÍA

### A. Modelado 3D

El dispositivo fue modelado en utilizando Autodesk Inventor 2024 (ver Fig.2), con las dimensiones y configuraciones óptimas para la inserción de los componentes electrónicos para la adquisición. Además, su diseño es ergonómico y práctico, con una ranura en la parte superior para colgarlo del cuello y un gancho en la parte posterior para sujetarlo al pantalón durante las mediciones.



**Fig. 2.** Vista isométrica del modelado 3D. (a) Vista isométrica del modelado 3D de la tapa (b) Vista isométrica del modelado 3D de la base

### B. Componentes electrónicos


El dispositivo contará con el kit BITalino (R)evolution, dispositivo electrónico formado por módulos individuales para la recolección de datos biomédicos, que es de costo accesible, no invasivo y comercial [20]. El voltaje adquirido se visualizó en el software OpenSignals, que permite adquisición en tiempo real y navegación sin conexión [21]. Asimismo, para el almacenamiento, se utilizará el microcontrolador ESP32 el cual almacenará los datos obtenidos del Bitalino, y estos datos serán posteriormente cargados y procesados mediante el uso de una tarjeta SD en el software correspondiente.

> REPLACE THIS LINE WITH YOUR MANUSCRIPT ID NUMBER (DOUBLE-CLICK HERE TO EDIT) <

Adicionalmente, el sistema integrará una batería de litio de 3.7V y un regulador de voltaje DC-DC.

### C. Adquisición de señales

La adquisición de las señales ECG se realizará a partir del protocolo de conexión de la guía BITalino HOME-GUIDE #2 ELECTROCARDIOGRAPHY (ECG) Exploring Cardiac Signals at the Skin Surface" [22] para la obtención de la primera derivada en la configuración bipolar de Einthoven [23]. La Figura 3 (ver Fig.3) ejemplifica el posicionamiento de los electrodos en el sujeto de prueba según la guía de referencia.



**Fig. 3.** Configuración bipolar para la primera derivada. (a) Posicionamiento de los electrodos en el sujeto de prueba: IN+ (rojo) e IN- (negro) en la clavícula y REF (blanco) en la cresta ilíaca. (b) Posicionamiento de los electrodos en el sujeto de prueba: IN+ (rojo) e IN- (negro) en las muñecas y REF (blanco) en la cresta ilíaca en dos configuraciones para obtener la primera derivada. [22]

Para el algoritmo, se utilizaron los datasets ECG de Physionet: MIT-BIH Normal Sinus Arrhythmia Interval Database, que incluye 54 registros de intervalos sinusales normales; la MIT-BIH Supraventricular Arrhythmia Database, que cuenta con 81 registros y la MIT-BIH Spontaneous Ventricular Tachyarrhythmia Database, que cuenta con 80 registros [24].

### D. Pre-procesamiento

Se utilizaron tres tipos de filtros para reducir el ruido en la señal de ECG, cada uno con frecuencias de corte específicas: un filtro pasa baja de 45 Hz, un filtro pasa alta de 0.5 Hz y un filtro rechazo de banda de 49-51 Hz para eliminar la interferencia de la línea de alimentación eléctrica, así como artefactos o ruidos durante la adquisición. Estos filtros fueron diseñados para suprimir eficazmente componentes específicos de la señal, como la interferencia de 50 Hz

La normalización empleada a la señal filtrada fue hacia un rango de 0 a 1. Se realizó, asimismo, una segmentación entre picos R-R con una ventana de 10s de señal ECG pre-procesada, con la finalidad de obtener cada latido de manera separada.

### E. Detección de picos R

La detección de picos R es la característica más resaltante de todo el complejo QRS y es la que se busca identificar para la clasificación de arritmias, ya que las demás características se extraen luego de la ubicación de este [25], para lo cual utilizamos un algoritmo de detección basado en la literatura [26][27]. Tras el filtrado y normalización de la señal, se aplica la transformación de energía no lineal de Shannon (SE), la cual permite rectificar y resaltar la región del complejo QRS,

facilitando la detección de los picos R. Se calculó utilizando la siguiente fórmula (Ecuación 1):

$$E_s(n) = -d^2(n) \log_2[d^2(n)] \quad (1)$$

Donde  $d(n)$  representa la señal filtrada y normalizada posteriormente.

### F. Extracción de características

Al obtener la posición de los picos R correctamente detectados, se procedió a realizar la extracción de características que utilizará el modelo de clasificación. Las características extraídas de cada ventana, obtenidas a partir de la literatura [28], incluyeron el promedio del intervalo (avgRR) entre picos máximo (maxRR) y mínimo (minRR), la desviación estándar de los intervalos (SDNN), la raíz cuadrada media de las diferencias sucesivas (rmsSD) y el número de intervalos RR donde la diferencia con el intervalo RR previo es mayor a 20 ms respecto al número total de intervalos RR (pNN20).

TABLA I  
CARACTERÍSTICAS EXTRAÍDAS DE CADA VENTANA

Características	Expresión matemática
minRR	-
maxRR	-
avgRR	-
SDNN	$SDNN = \sqrt{\frac{1}{N-1} * \sum_{i=1}^N (RR_i - \overline{RR})^2}$ , donde $(RR_i)$ es cada intervalo RR y $(\overline{RR})$ es el promedio de todos los intervalos RR.
rmsSD	$rmsSD = \sqrt{\frac{\sum_{i=1}^{N-1} (RR_{i+1} - RR_i)^2}{N-1}}$ , donde $(RR_{i+1} - RR_i)$ representa la diferencia entre intervalos RR sucesivos
pNN20	$pNN20 = \frac{\sum_{i=1}^{N-1} I(RR_{i+1} - RR_i) > 20ms}{N-1}$

### G. Clasificación

La clasificación entre los cuatro tipos de arritmia evaluadas en el artículo se realizó a partir del modelo de clasificación utilizado para la predicción basado en cada característica es el algoritmo de *machine learning* de K-Nearest Neighbors (kNN), un método estadístico caracterizado por su simplicidad y efectividad [29]. Este algoritmo calcula una predicción de un dato no etiquetado o de prueba utilizando un conjunto de datos etiquetados. Matemáticamente, el procedimiento comienza con el cálculo de la distancia euclidiana entre las muestras de entrenamiento y las nuevas muestras. Una vez encontrados los K vecinos, se determina la categoría de la nueva muestra a partir de los datos no etiquetados. Se evaluó el desempeño del kNN utilizando un conjunto de entrenamiento del 80% y un conjunto de prueba del 20%. Asimismo, se evaluó la precisión de la clasificación, así como la matriz de confusión para determinar si las características analizadas son adecuadas para los tipos de arritmia designados. Por último, para la evaluación del KNN se usa el formato *pickle*, el cual será subido al

> REPLACE THIS LINE WITH YOUR MANUSCRIPT ID NUMBER (DOUBLE-CLICK HERE TO EDIT) <

software.


#### H. Visualización de datos mediante HL7

Se desarrolló un software que permitirá la visualización de los datos adquiridos y el tipo de arritmia que el paciente este experimentando. Asimismo, se generará una base de datos para el historial de los pacientes y proporcionará la capacidad de exportar los datos en formato HL7 que se visualizará en Core HL7 Viewer, asegurando así la compatibilidad y la interoperabilidad con otros sistemas de información de salud. Esta funcionalidad permitirá una integración eficiente y estandarizada de los datos con los sistemas existentes en diversas instituciones de salud

### V. RESULTADOS Y DISCUSIÓN

#### A. Resultados del pre-procesamiento


El sistema desarrollado demostró eficiencia al obtener mediciones precisas a partir de una única derivación electrocardiográfica utilizando tres electrodos. A continuación, se observa en la Figura 4. los resultados de la aplicación del filtrado en la señal adquirida de las arritmias. La efectividad del filtrado se cuantifica mediante la relación señal a ruido (SNR), en las que se obtuvo valores de 0.06 dB para la señal filtrada y -21.28 dB para la señal no filtrada. indica la mejora en la calidad de la señal procesada.



**Fig. 4.** Comparación de la señal original versus la señal filtrada tras la aplicación del filtrado

#### B. Detección de picos R

La detección de picos R en la señal ECG fueron detectados como puntos, como se especificó en la metodología (ver Figura 5). Se identifica los máximos locales en la señal que cumplen ciertos criterios, como una altura mínima y una distancia mínima entre picos consecutivos. En el contexto de la detección de picos R, se especifica una distancia mínima de 0.6 segundos (600 ms), asegurando que los picos estén separados adecuadamente para representar correctamente los latidos del corazón.



**Fig. 5.** Resultados de los picos R detectados en la señal filtrada

#### C. Características extraídas


Las características extraídas para la primera ventana de análisis que se observan en la Tabla II. Si bien se extrayeron características adicionales, estas no fueron consideradas para el análisis pues no brindaban resultados eficientes, por lo que se escogió las observadas.

**TABLA II**  
RESULTADOS DE LAS CARACTERÍSTICAS EXTRAÍDAS

Características característico	Resultados
MinRR	0.617
MaxRR	1.016
avgRR	0.8509736
SDNN	0.1162722
rmsSD	0.1140148
pNN20	0.3157894

#### D. Resultados del modelo

Los resultados del modelo de clasificación kNN permitió obtener una identificación de las mejores características extraídas. Para tales fines, se obtuvo el diagrama de cajas y bigote para la visualización. El resultado obtenido menciona las características extraídas mejor distribuidas.



**Fig 6.** Diagrama de cajas y bigote para la visualización de los outliers

La Tabla III resalta los resultados obtenidos tras la clasificación de las señales. Estos resultados destacan la



> REPLACE THIS LINE WITH YOUR MANUSCRIPT ID NUMBER (DOUBLE-CLICK HERE TO EDIT) <

robustez y precisión del modelo kNN para distinguir entre ritmos cardíacos normales y arrítmicos en las 54 señales evaluadas para cada tipo. La baja tasa de error y la alta precisión indican que el modelo puede generalizar bien a nuevas señales y tiene una capacidad efectiva para el diagnóstico diferencial.

TABLA III  
RESULTADOS DEL KNN

Resultado	Porcentaje
Error de clasificación	2.7%
Precisión de clasificación	97.3%

Asimismo, se observa en la Tabla V los resultados obtenidos a partir de la matriz de confusión en donde se consideró los siguientes parámetros:

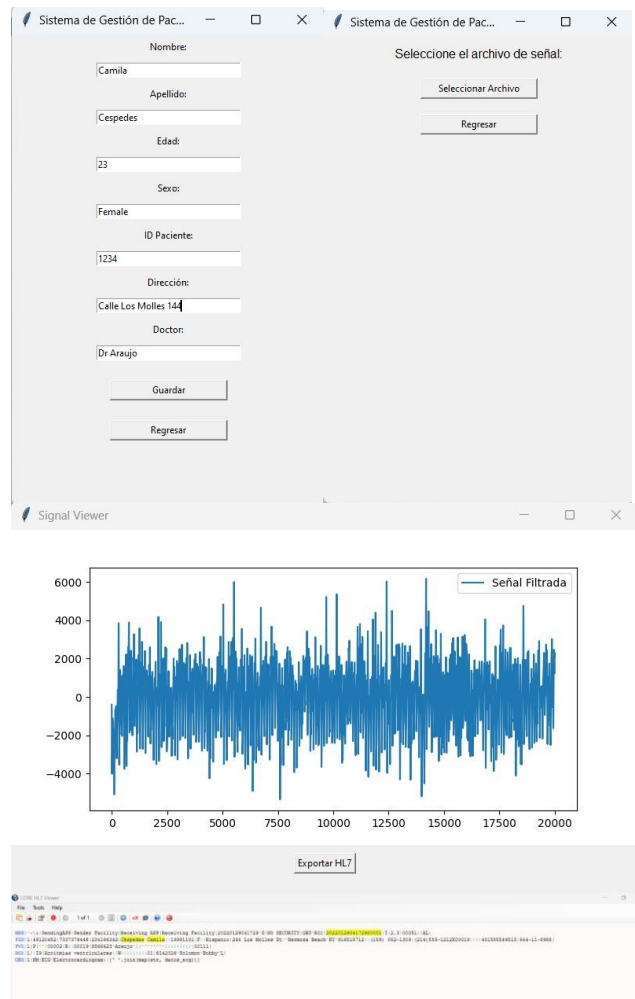
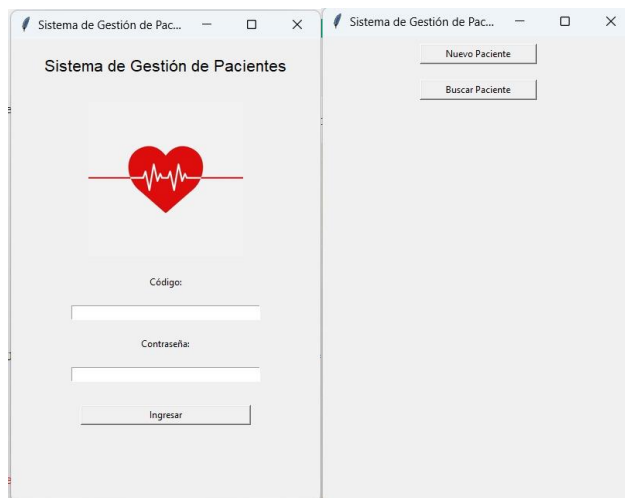
- Verdaderos Positivos (TP): señales arrítmicas correctamente identificadas.
- Verdaderos Negativos (TN): señales normales correctamente identificadas.
- Falsos Positivos (FP): señales normales incorrectamente clasificadas como arrítmicas.
- Falsos Negativos (FN): señales arrítmicas incorrectamente clasificadas como normales.

TABLA IV  
RESULTADOS DE LA MATRIZ DE CONFUSIÓN

Parámetro característico	Resultados
Verdaderos positivos	48
Verdaderos negativos	52
Falsos positivos	2
Falsos negativos	2

#### E. Software

La Figura 7 ejemplifica la interfaz generada para la visualización y transmisión de los datos adquiridos. Estas mediciones son almacenadas de manera segura y, luego, analizadas, permitiendo la gestión integral de datos, y la integración necesaria para el estándar HL7. Se ha implementado un estricto protocolo de acceso para asegurar la confidencialidad de los datos, restringiendo el ingreso únicamente a personal autorizado.



**Fig 7.** Software para la visualización de datos del sistema. Se visualiza, además, la comprobación con Core HL7 Viewer.

#### VI. CONCLUSIONES

El desarrollo de un sistema de clasificación de arritmias utilizando algoritmos de deep learning e integración con el estándar HL7 representa un avance significativo en el manejo de enfermedades cardiovasculares. Este enfoque no solo mejora la precisión en la detección de arritmias, sino que también facilita la interoperabilidad y el intercambio de información médica crucial entre diferentes sistemas de salud. La implementación del sistema en áreas rurales y con escasos recursos médicos puede tener un impacto positivo en la atención de pacientes con arritmias, permitiendo un diagnóstico más temprano y preciso, y reduciendo potencialmente las tasas de mortalidad asociadas a estas condiciones. Los resultados obtenidos subrayan la viabilidad y la efectividad del uso de tecnologías avanzadas en la mejora de la salud pública, destacando la importancia de seguir desarrollando soluciones integradas y automatizadas para el diagnóstico médico.

#### REFERENCIAS

- [1] "Cardiovascular diseases (CVDs)." <https://www.who.int/news-room/factsheets/detail/cardiovascular-diseases-cvds>

> REPLACE THIS LINE WITH YOUR MANUSCRIPT ID NUMBER (DOUBLE-CLICK HERE TO EDIT) <

- [2] Ministerio de Salud (MINSA), "El 50.8 % de personas de 60 años a más tienen muy alto riesgo de padecer de enfermedades cardiovasculares" [En línea]. Disponible en: <https://www.gob.pe/institucion/minsa/noticias/655525-el-50-8-de-personas-de-60-anos-a-mas-tienen-muy-alto-riesgo-de-padecer-de-enfermedades-cardiovasculares>.
- [3] A. S. Go et al., "Prevalence of Diagnosed Atrial Fibrillation in Adults," *Jama*, vol. 285, no. 18, p. 2370, 2001, doi: 10.1001/jama.285.18.2370
- [4] "Ventricular Tachycardia - StatPearls - NCBI Bookshelf." <https://www.ncbi.nlm.nih.gov/books/NBK532954/>
- [5] C. Pandozi et al., "Mapping of ventricular tachycardia in patients with ischemic cardiomyopathy: Current approaches and future perspectives," *Clin. Cardiol.*, vol. 42, no. 10, pp. 1041–1050, 2019, doi: 10.1002/clc.23245
- [6] "Ecgaware: An ECG markup language for ambulatory telemonitoring and decision making support," in Proceedings of the First International Conference on Health Informatics
- [7] (N.d.). Gob.Pe. Retrieved July 5, 2024, from <http://bvs.minisa.gob.pe/local/minsa/3107-2.pdf>
- [8] "Integrating Patient-Generated Health Data into Electronic Health Records in Ambulatory Care Settings: A Practical Guide," Ahrq.gov, Dec-2021. [Online]. Available: <https://digital.ahrq.gov/sites/default/files/docs/citation/pghd-practical-guide.pdf>.
- [9] Lee, J., & Shin, M. (2023). Method for solving difficulties in rhythm classification caused by few samples and similar characteristics in electrocardiograms. *Bioengineering (Basel, Switzerland)*, 10(2), 196. <https://doi.org/10.3390/bioengineering10020196>
- [10] A. Walinjar and J. Woods, "Personalized wearable systems for real-time ECG classification and healthcare interoperability: Real-time ECG classification and FHIR interoperability," in 2017 Internet Technologies and Applications (ITA), 2017.
- [11] J. Park, K. Lee, and K. Kang, "Arrhythmia detection from heartbeat using k-nearest neighbor classifier," in 2013 IEEE International Conference on Bioinformatics and Biomedicine, 2013.
- [12] K. Ramasamy, K. Balakrishnan, and D. Velusamy, "Detection of cardiac arrhythmias from ECG signals using FBSE and Jaya optimized ensemble random subspace K-nearest neighbor algorithm," *Biomed. Signal Process. Control*, vol. 76, no. 103654, p. 103654, 2022.
- [13] National Library of Medicine. (2020). MedlinePlus. [Online]. Available: <https://medlineplus.gov/lab-tests/electrocardiogram/>
- [14] J. Huang, B. Chen, B. Yao, and W. He, "ECG Arrhythmia Classification Using STFT-Based Spectrogram and Convolutional Neural Network," *IEEE Access*, vol. 7, pp. 92871–92880, 2019. doi: 10.1109/ACCESS.2019.2928017.
- [15] B. Pyakillya, N. Kazachenko, and N. Mikhailovsky, "Deep Learning for ECG Classification," *Journal of Physics: Conference Series*, vol. 913, p. 012004, 2017. doi: 10.1088/1742-6596/913/1/012004.
- [16] World Health Organization, "World Health Organization," [Online]. Available: <https://www.who.int/en/news-room/fact-sheets/detail/cardiovascular-diseases-cvds>. Accessed: June 11, 2021.
- [17] K. K. Verma, "Deep Learning Approach to Recognize COVID-19, SARS and Streptococcus," *Journal of Scientific & Industrial Research*, vol. 80, no. 01, pp. 51–59, 2021.
- [18] Badilini F., Young B., Brown B., Vaglio M. Archiving and exchange of digital ECGs: A review of existing data formats. *J. Electrocardiol.* 2018;51:S113–S115. doi: 10.1016/j.jelectrocard.2018.07.028.
- [19] Olamidipupo S.A., Danas K. Review of interoperability techniques in data acquisition of wireless ECG devices. *IOSR J. Mob. Comput. Appl.* 2015;2:19–25.
- [20] "BITalino," PLUX Biosignals. [Online]. Available: <https://www.pluxbiosignals.com/collections/bitalino>. [Accessed: 03-Jul-2024].
- [21] "OpenSignals," PLUX Biosignals. [Online]. Available: <https://www.pluxbiosignals.com/collections/opensignals>. [Accessed: 03-Jul-2024].
- [22] PLUX – Wireless Biosignals, "BITalino (r)evolution Lab Guide," Feb. 2021. Available: [https://support.pluxbiosignals.com/wp-content/uploads/2022/04/HomeGuide2\\_ECG.pdf](https://support.pluxbiosignals.com/wp-content/uploads/2022/04/HomeGuide2_ECG.pdf)
- [23] N. Dugarte Jerez, E. Dugarte Dugarte, and N. Dugarte Dugarte, *Electrocardiografía de Alta Resolución Técnicas Aplicadas de Adquisición y Procesamiento*, 1st ed. Mendoza – Argentina: Universidad Tecnológica Nacional – Facultad Regional Mendoza, 2018. [https://www.researchgate.net/publication/324690144\\_Electrocardiografia\\_de\\_Alta\\_Resolucion\\_Tecnicas\\_Aplicadas\\_de\\_Adquisicion\\_y\\_Procesamiento](https://www.researchgate.net/publication/324690144_Electrocardiografia_de_Alta_Resolucion_Tecnicas_Aplicadas_de_Adquisicion_y_Procesamiento)
- [24] A. Goldberger, L. Amaral, L. Glass, J. Hausdorff, P. C. Ivanov, R. Mark, ... and H. E. Stanley, "PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals," *Circulation* [Online], vol. 101, no. 23, pp. e215–e220, 2000.
- [25] P. Borghi, E. Kuhn, J. P. Teixeira, and G. Lazaretti, "Android-based ECG monitoring system for atrial fibrillation detection using a BITalino® ECG sensor," in *Proceedings of the 15th International Joint Conference on Biomedical Engineering Systems and Technologies (BIOSTEC 2022)*, vol. 1, pp. 177–184, 2022. ISBN 978-989-758-552-4.
- [26] A. Kaur, A. Agarwal, R. Agarwal, and S. Kumar, "A novel approach to ECG R-Peak detection," *Arabian Journal for Science and Engineering*, vol. 44, no. 8, 2019. doi: 10.1007/s13369-018-3557-8.
- [27] M. S. Manikandan and K. P. Soman, "A novel method for detecting R-peaks in electrocardiogram (ECG) signal," *Biomedical Signal Processing and Control*, vol. 7, no. 2, pp. 118–128, 2012. doi: 10.1016/j.bspc.2011.03.004.
- [28] G. Ramos, M. Alfaras, and H. Gamboa, "Real-Time Approach to HRV Analysis," in Proceedings of the 11th International Joint Conference on Biomedical Engineering Systems and Technologies (BIOSTEC 2018), vol. 4: BIOSIGNALS, pp. 208–215, 2018, doi: <https://dx.doi.org/10.5220/0006641402080215>
- [29] K. Taunk, S. De, S. Verma, and A. Swetapadma, "A Brief Review of Nearest Neighbor Algorithm for Learning and Classification," 2019 International Conference on Intelligent Computing and Control Systems (ICCS), May 2019, doi: 10.1109/iccs45141.2019.9065747.



**Sofía Céspedes** Senior year student of Biomedical Engineering at PUCP-UPCH. Passionate about materials, nanotechnology, and Tissue and Materials Engineering. Currently a researcher in the materials modification group (Mod-MAT PUCP).



**Chris Viviano** (Seventh semester student of Biomedical Engineering at PUCP-UPCH, with an interest in Tissue and Materials Engineering. Currently part of the Clinical Engineering Research, Innovation, and Development Group (GIIDIC).



**Nicole Acuña** Ninth semester student of Biomedical Engineering at PUCP-UPCH, interested in the application of biomedical engineering in clinical settings. Currently working on a research project with the Materials Science and Renewable Energy Group (MatEr).



**Harold Alemán** Biomedical Engineering student at PUCP-UPCH. Currently doing internships at the National Children's Institute and in medical simulation at UPCH. Additionally, runs a company dedicated to using technology to optimize agricultural processes.